MBA Em Data Science

Projeto 04 - Análise Exploratória de Dados

EDA

Nome: Carla Cristina Assis Chagas de Lima

Nome da disciplina: Estatística para Cientistas de Dados

Turno: Noite (live)

Professor: Edineide Ramalho

Abril/2026

Nessa disciplina, aprofundamos nossos conhecimentos na linguagem R e de estatística, para realizar análises descritivas de bases de dados, tarefa que é extremamente importante para o dia-a-dia de um cientista de dados. Agora iremos validar nosso conhecimento.

1. **O relatório final deve ser apresentado utilizando RMarkdown. Nesse relatório devem haver:**
    a. **imagens estáticas ("prints" de tela, imagens da internet - com a devida fonte mencionada - ou figuras criadas pelo aluno fora do ambiente do R);**
    b. **imagens geradas através do ambiente R, particularmente com a biblioteca ggplot;**
    c. **links clicáveis (como fontes e referências).**
2. **Escolha uma base de dados para realizar esse projeto. Essa base de dados será utilizada durante toda sua análise. Essa base necessita ter 4 (ou mais) variáveis de interesse, onde todas são numéricas (confira com o professor a possibilidade de utilização de dados categóricos). Observe que é importante que haja dados faltantes em pelo menos uma variável para executar esse projeto. Caso você tenha dificuldade para escolher uma base, o professor da disciplina irá designar para você. Explique qual o motivo para a escolha dessa base e aponte os resultados esperados através da análise.**

Resposta: As variáveis escolhidas foram idade (age), índice de massa corporal (bmi), horas de sono (sleep) e nível de atividade física (exercise). pois contém variáveis numéricas relevantes relacionadas à saúde e estilo de vida.

Essas variáveis permitem analisar a relação entre estilo de vida e saúde, possibilitando identificar padrões de risco.

A intenção é identificar relações entre hábitos de vida e indicadores físicos, como possíveis associações entre sono, atividade física e índice de massa corporal.

3. **Utilizando o pacote summarytools (função descr), descreva estatisticamente a sua base de dados.**

Resposta:

```r
{r}
#questão 03
descr(df_num)
```

```
Non-numerical variable(s) ignored: exercise

Descriptive Statistics
df_num
N: 5000

                        age       bmi     sleep
----------------- --------- --------- ---------
             Mean     48.81     26.84      7.00
          Std.Dev     17.91      8.25      1.43
              Min     18.00     11.40      3.00
               Q1     34.00     20.30      6.00
           Median     49.00     26.00      7.00
               Q3     64.00     32.40      8.00
              Max     79.00     51.40     10.00
              MAD     22.24      8.90      1.48
              IQR     30.00     12.10      2.00
               CV      0.37      0.31      0.20
         Skewness     -0.01      0.47     -0.06
      SE.Skewness      0.03      0.03      0.03
         Kurtosis     -1.18     -0.36     -0.33
          N.Valid   5000.00   5000.00   5000.00
                N   5000.00   5000.00   5000.00
        Pct.Valid    100.00    100.00    100.00
```

Uma análise descritiva permite saber as medidas como média, mediana, desvio padrão e presença de valores faltantes.

As variáveis acima apresentam diferentes escalas e dispersões, isso é muito importante para entender o comportamento inicial dos dados antes de análises mais profundas.

4. **Crie um gráfico com a matriz de espalhamento (*scatter matrix plot*) para sua base de dados. Através de investigação visual, quais são as variáveis mais correlacionadas. Apresente o gráfico e justifique.**

Resposta:

```r
{r}
#questão 04
library(GGally)

ggpairs(df_num)
```

```
plot: [1, 1] [=>----------]  6% est: 0s
plot: [1, 2] [=====>----------] 12% est: 2s
plot: [1, 3] [========>----------] 19% est: 2s
plot: [1, 4] [===========>----------] 25% est: 2s
plot: [2, 1] [==============>----------] 31% est: 2s
plot: [2, 2] [=================>----------] 38% est: 2s
plot: [2, 3] [====================>----------] 44% est: 2s
plot: [2, 4] [========================>----------] 50% est: 2s
plot: [3, 1] [============================>----------] 56% est: 2s
plot: [3, 2] [================================>----------] 62% est: 1s
plot: [3, 3] [===================================>----------] 69% est: 1s
plot: [3, 4] [=========================================>----------] 75% est: 1s
plot: [4, 1] [==============================================>---------] 81% est: 1s
`stat_bin()` using `bins = 30`. Pick better value `binwidth`.
plot: [4, 2] [=================================================>------] 88% est: 1s
`stat_bin()` using `bins = 30`. Pick better value `binwidth`.
plot: [4, 3] [====================================================>---] 94% est: 0s
`stat_bin()` using `bins = 30`. Pick better value `binwidth`.
plot: [4, 4] [==================================================]100% est: 0s
```

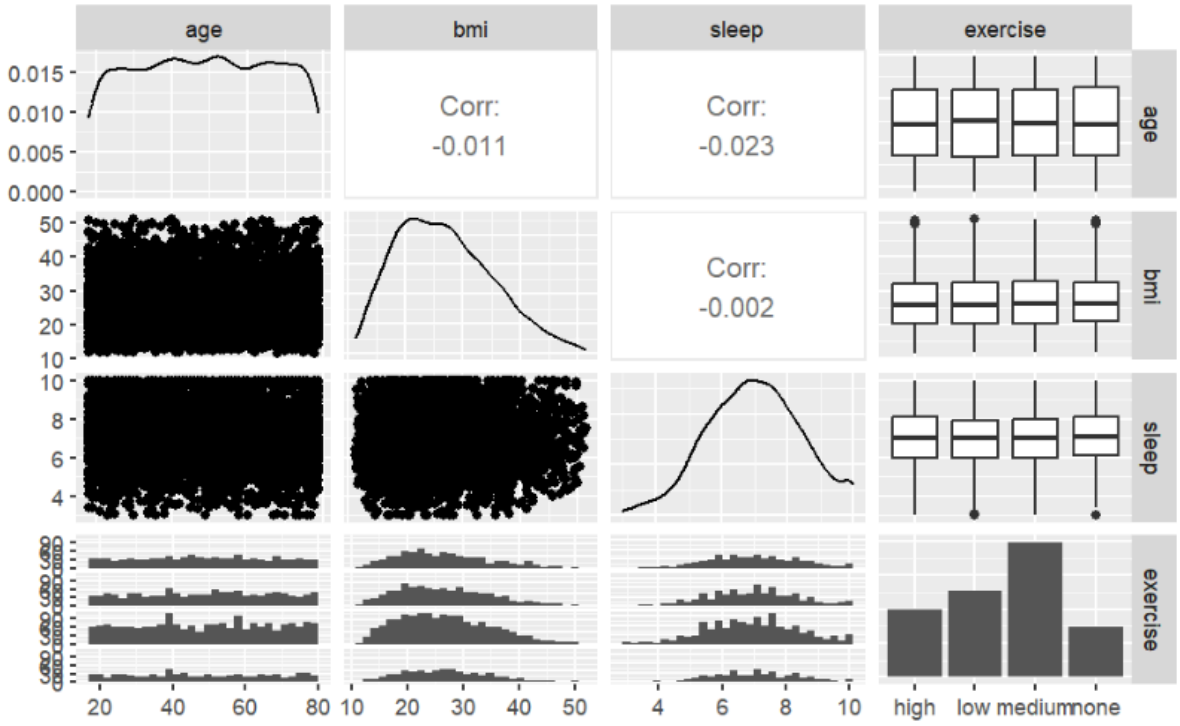

Pela matriz de dispersão, algumas variáveis apresentam relação entre si. Por exemplo, pode-se identificar uma relação entre BMI e nível de exercício, indicando que indivíduos mais ativos tendem a apresentar menor índice de massa corporal. Também é possível ver padrões entre sono e atividade física, sugerindo que hábitos saudáveis podem estar interligados.

5. **Sobre a normalidade das variáveis:**
    a. **Descreva o que é uma distribuição normal;**

Resposta: Uma distribuição normal é simétrica, em formato de sino, onde média, mediana e moda coincidem.

b. **Crie um histograma para cada variável da sua base de dados. Justifique a escolha do número de bins para seu trabalho. (usando o pacote ggplot);**

Resposta: Precisei mudar a variável exercise (categórica) para weight por ser uma numérica contínua para poder exibir o histograma.

O valor de 30 bins é uma escolha padrão que permite ter uma boa visualização da distribuição dos dados.

```r
#questão 05


df_num <- df |>
  select(age, bmi, sleep, weight)

#necessário trocar a variável exercise por uma númerica de verdade "weight"
```

```r
{r}
str(df_num)
```

```
'data.frame':	5000 obs. of  4 variables:
 $ age   : int  56 69 46 32 60 25 78 38 56 75 ...
 $ bmi   : num  17.6 26.3 45.3 15.6 25.8 37.5 22.7 20.2 23.2 43.5 ...
 $ sleep : num  6.1 6.9 6.6 8.5 8 3.8 9.9 6.6 9.6 8.1 ...
 $ weight: int  67 76 106 54 98 96 64 76 58 94 ...
```

```r
{r}
library(ggplot2)
```

```r
{r}
df_num <- df |>
  select(age, bmi, sleep, weight)

# Histograma - age
ggplot(df_num, aes(x = age)) +
  geom_histogram(bins = 30, fill = "blue", alpha = 0.7)

# Histograma - bmi
ggplot(df_num, aes(x = bmi)) +
  geom_histogram(bins = 30, fill = "green", alpha = 0.7)

# Histograma - sleep
ggplot(df_num, aes(x = sleep)) +
  geom_histogram(bins = 30, fill = "purple", alpha = 0.7)

# Histograma - weight
ggplot(df_num, aes(x = weight)) +
  geom_histogram(bins = 30, fill = "orange", alpha = 0.7)
```

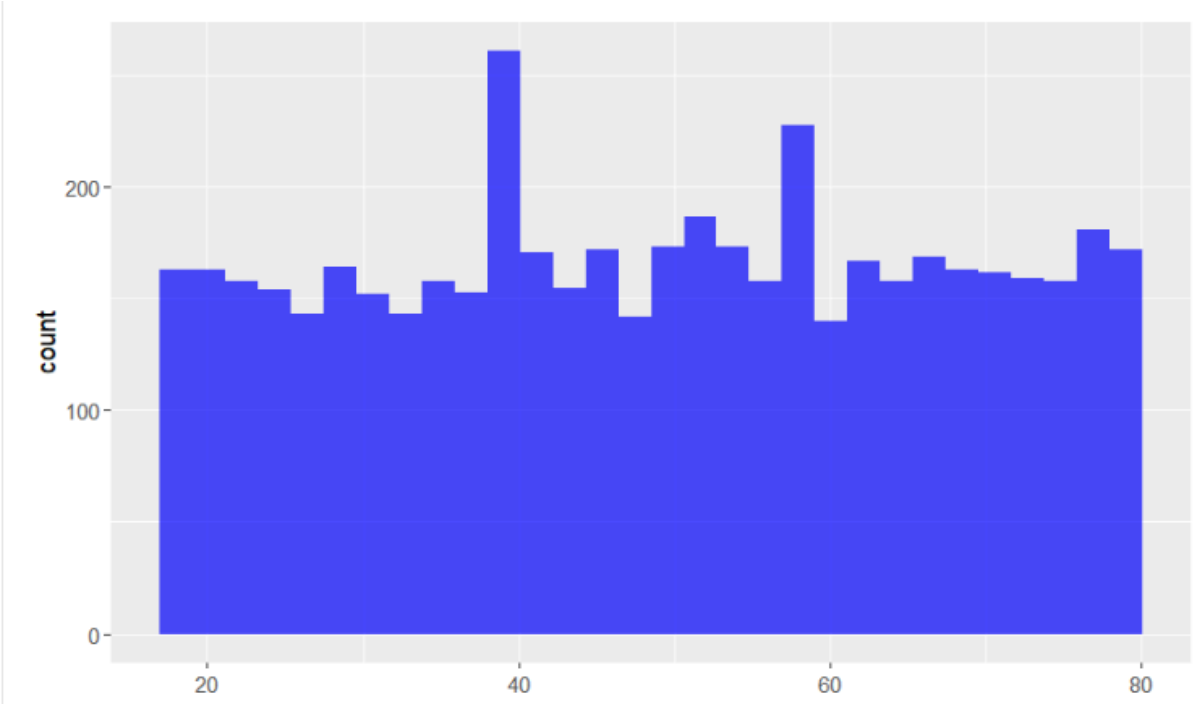
count
200
100
0
20
40
60
80

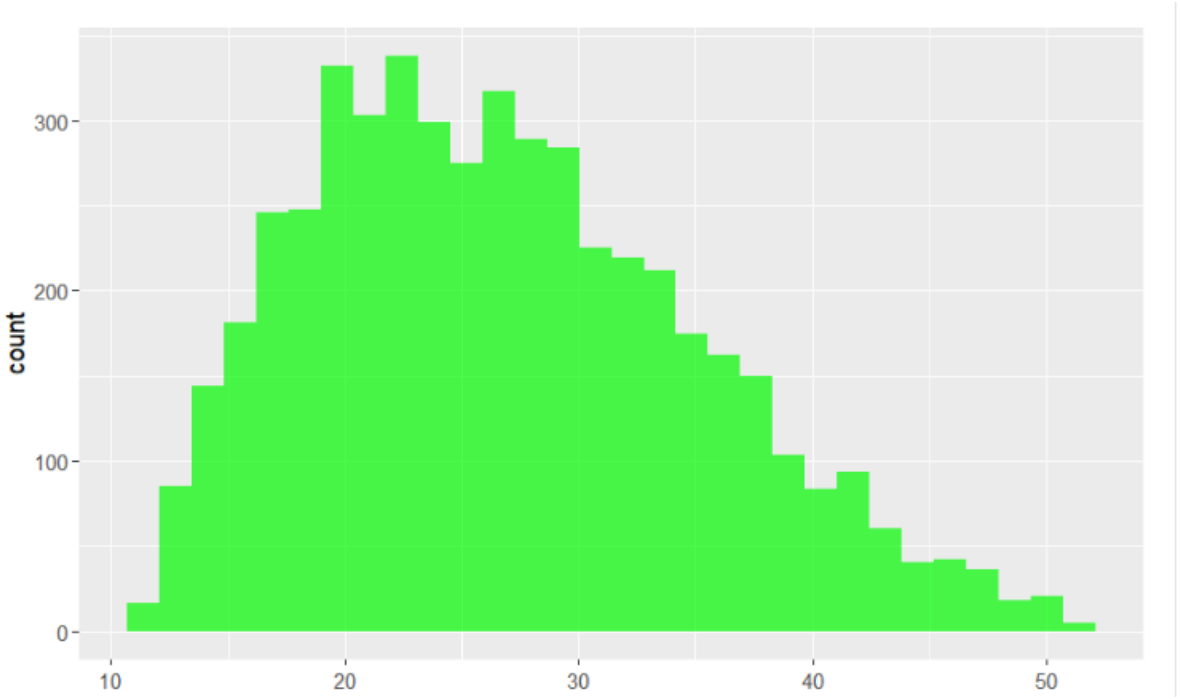
count
300
200
100
0
10
20
30
40
50

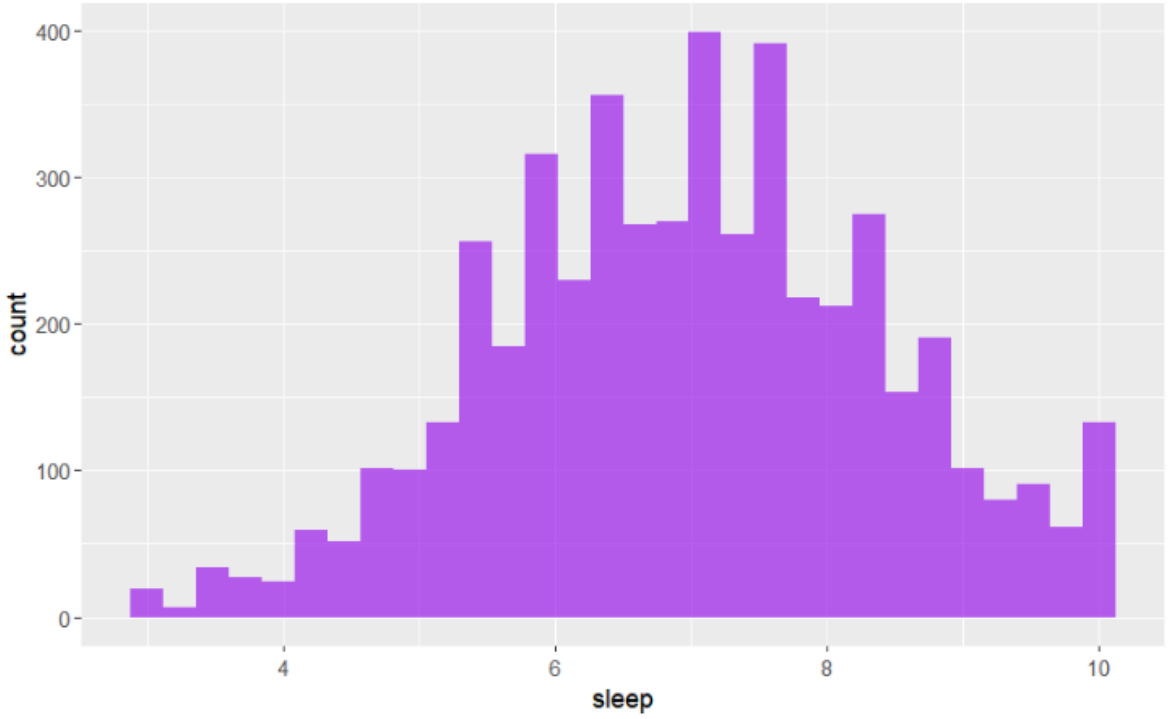
400
300
200
100
0
count
4
6
8
10
sleep

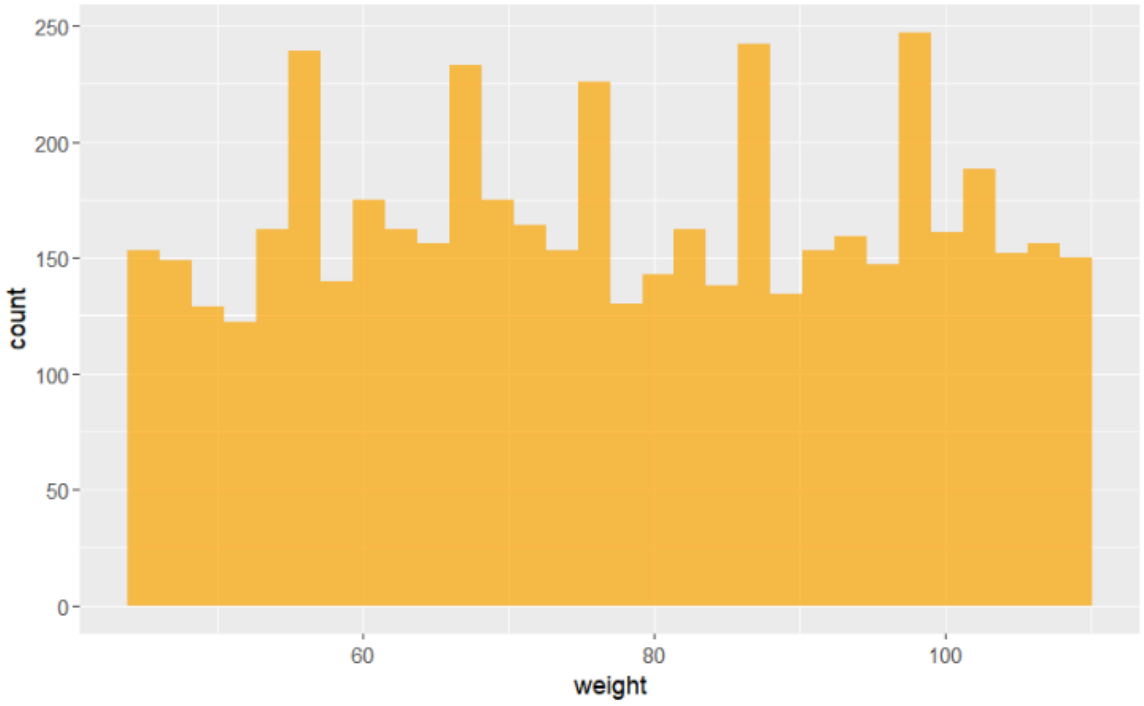
250
200
150
100
50
0
count
60
80
100
weight

c. **Crie um gráfico Q-Q para cada variável de sua base de dados. (use as funções presentes no pacote ggpubr);**

Resposta:

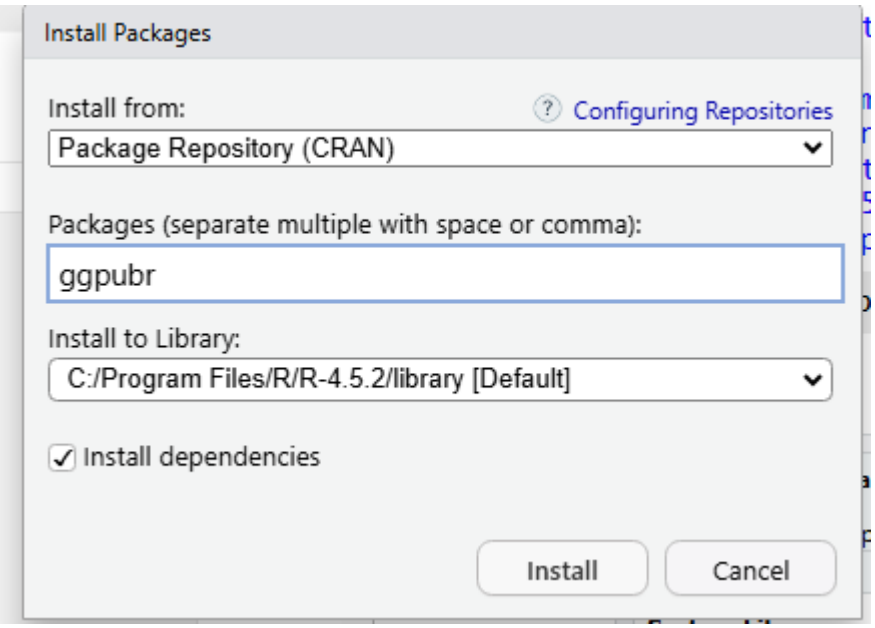


```r
{r}
#questão 05 letra c:
library(ggpubr)

# Q-Q plot - age
ggqqplot(df_num$age)

# Q-Q plot - bmi
ggqqplot(df_num$bmi)

# Q-Q plot - sleep
ggqqplot(df_num$sleep)

# Q-Q plot - weight
ggqqplot(df_num$weight)
```

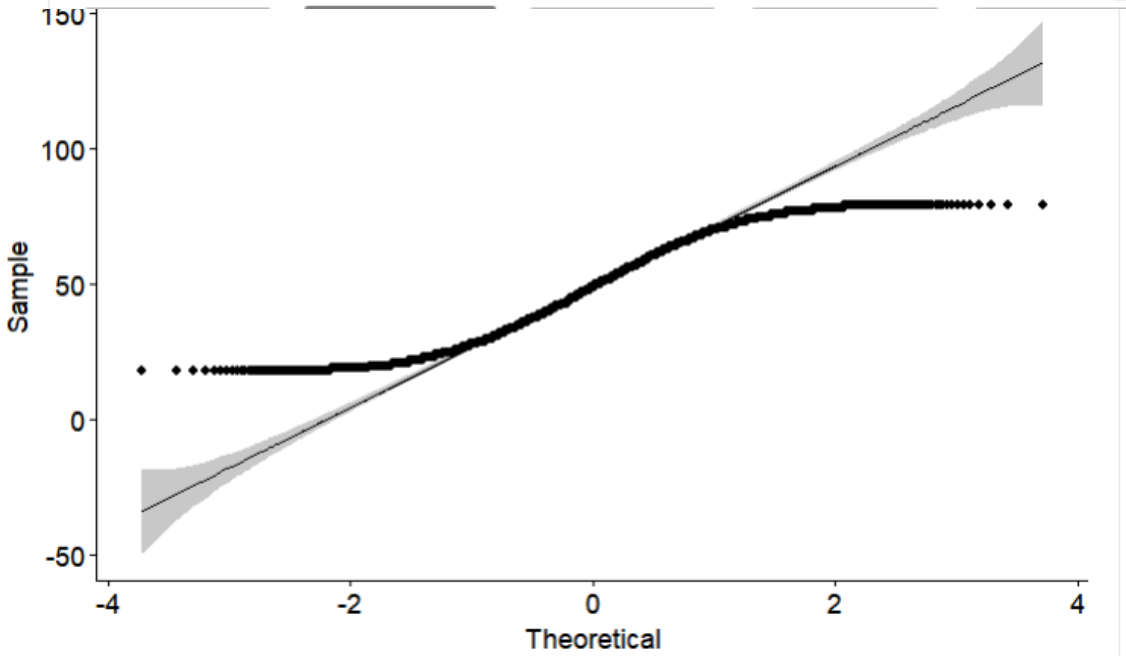

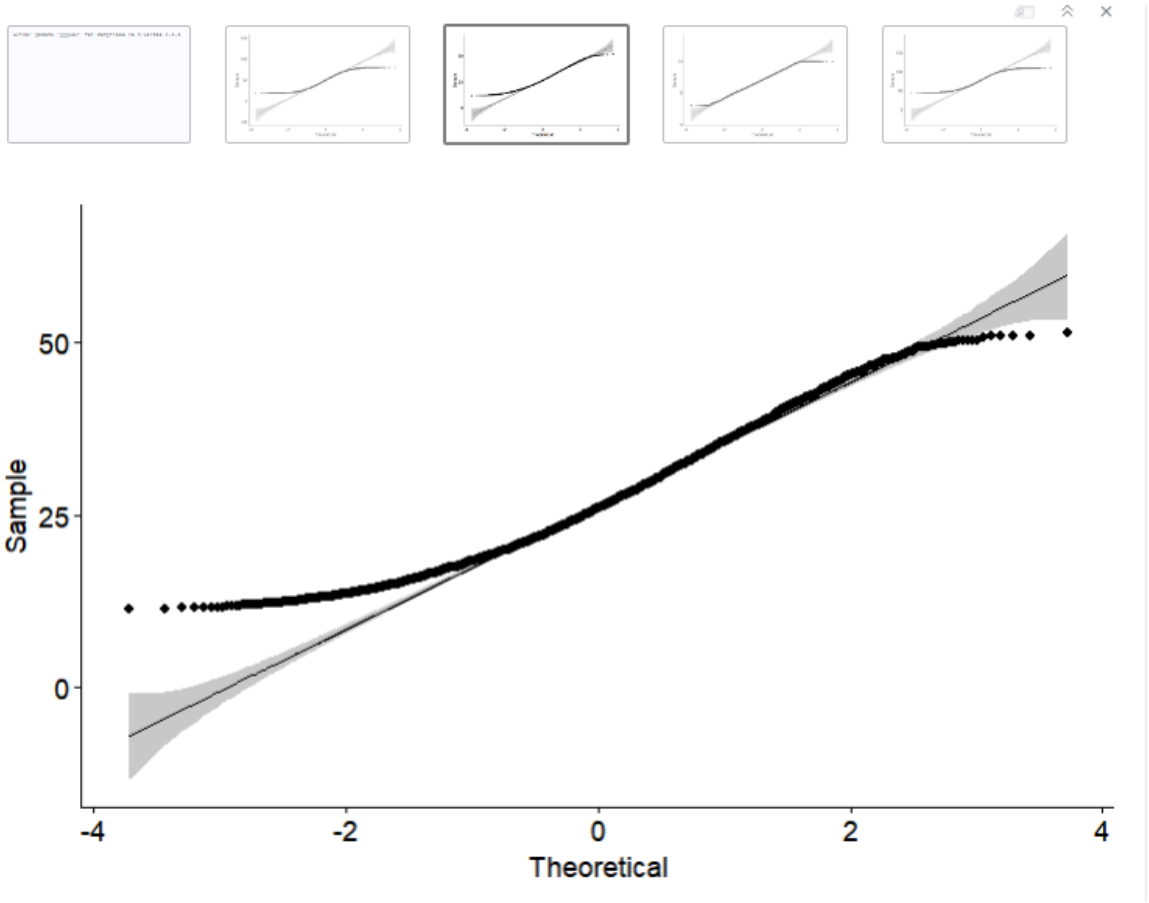
Sample
50
25
0
-4
-2
0
2
4
Theoretical

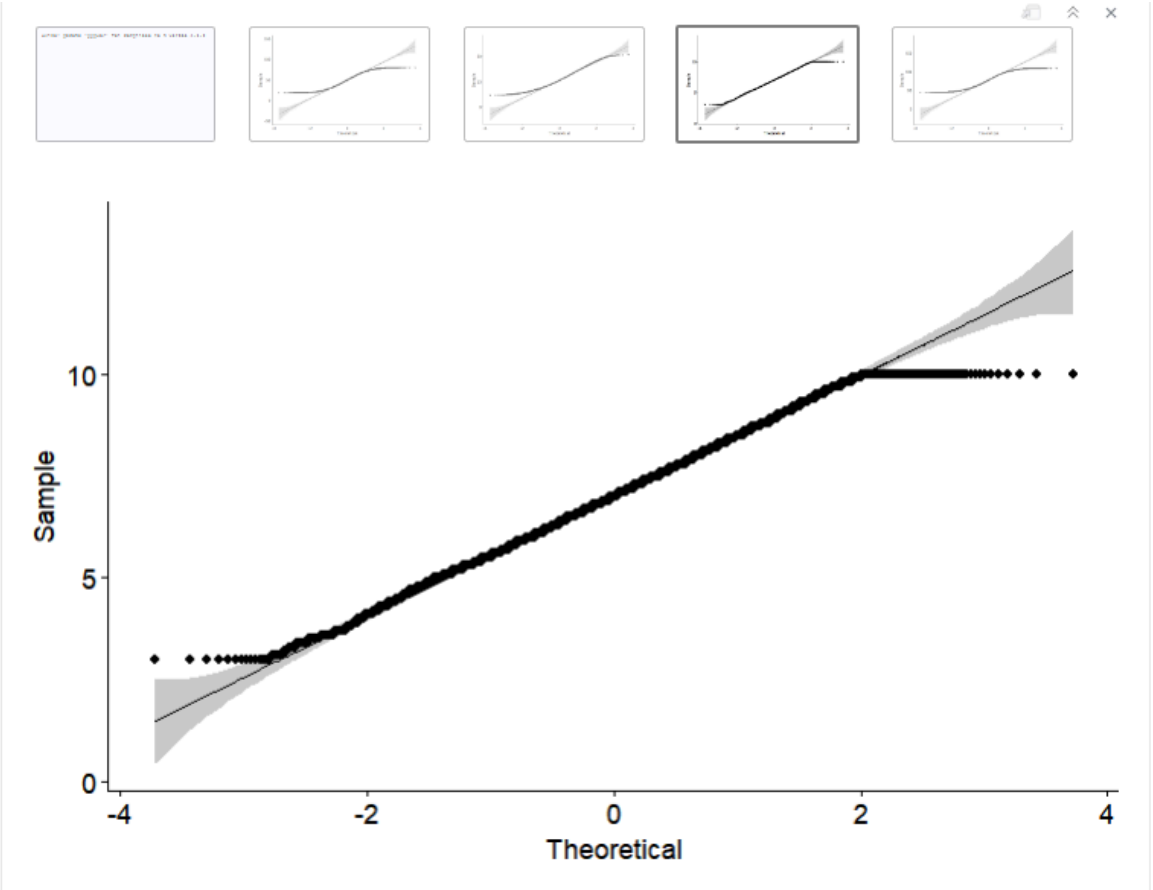
Sample
10
5
0
-4
-2
0
2
4
Theoretical

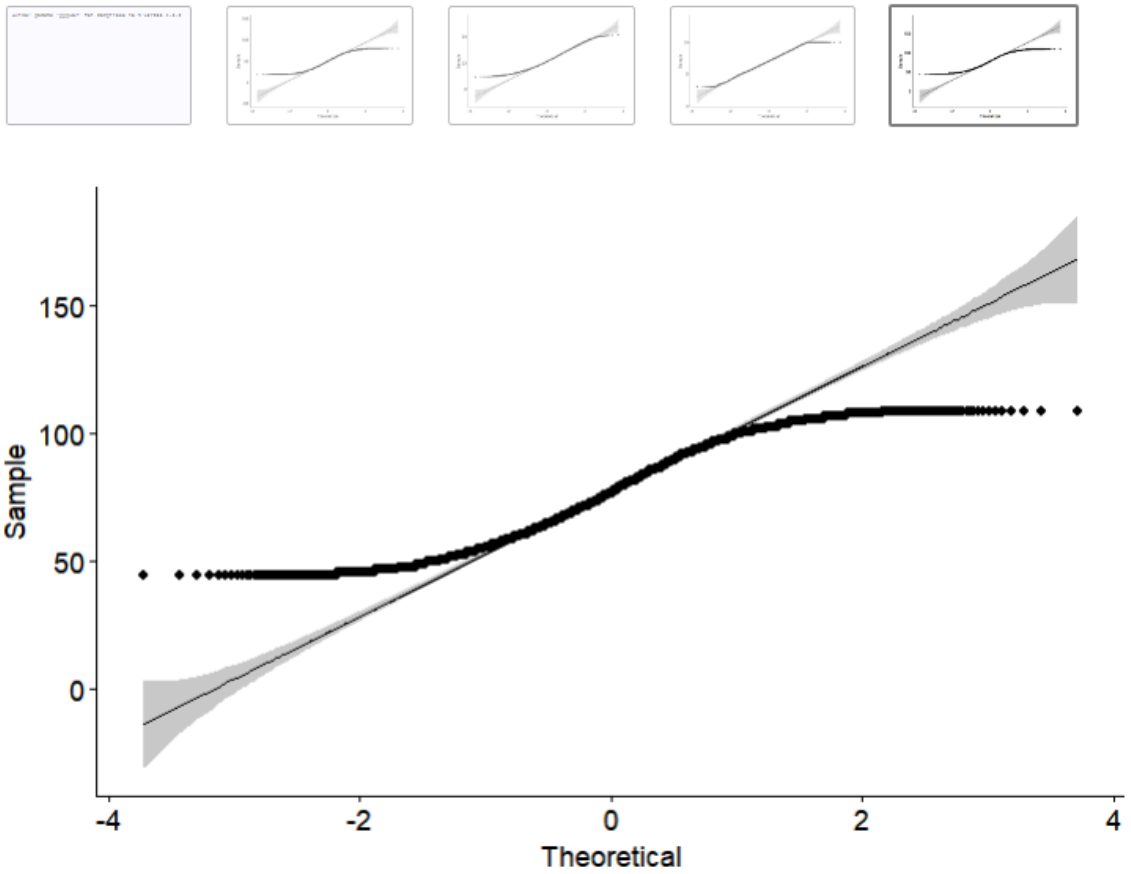
150
100
50
0
Sample
-4
-2
0
2
4
Theoretical

d. **Execute um teste de normalidade Shapiro-Wilk;**

Resposta:

```r
{r}
#questão 5 letra d:
shapiro.test(df_num$age)
shapiro.test(df_num$bmi)
shapiro.test(df_num$sleep)
shapiro.test(df_num$weight)
```

```
        Shapiro-Wilk normality test

data:  df_num$age
W = 0.9553, p-value < 2.2e-16


        Shapiro-Wilk normality test

data:  df_num$bmi
W = 0.97541, p-value < 2.2e-16


        Shapiro-Wilk normality test

data:  df_num$sleep
W = 0.99413, p-value = 1.968e-13


        Shapiro-Wilk normality test

data:  df_num$weight
W = 0.95387, p-value < 2.2e-16
```

e. **Baseado nos itens anteriores, é possível afirmar que algumas das variáveis se aproximam de uma distribuição normal? Justifique.**

Resposta: Com base nos teste realizados acima, em Q-Q plot e Shapiro, não é possível afirmar que as variáveis seguem uma distribuição normal. No teste de Shapiro-Wilk que é bastante sensível, todas as variáveis foram menores que 0,05 e isso anula a normalidade. Estatisticamente, nenhuma das variáveis apresenta distribuição normal.

Entretanto, nos gráficos Q-Q, podemos observar que algumas variáveis, sleep e bmi, apresentam pontos relativamente próximos à linha de referência, sugerindo uma leve aproximação da normalidade.

Mesmo assim existem desvios, principalmente nas extremidades, o que confirma os resultados do teste estatístico.

Podemos concluir que mesmo que algumas variáveis apresentam comportamento visual próximo ao normal, nenhuma delas pode ser considerada normalmente distribuída do ponto de vista estatístico.

6. **Qualidade de dados tem sido um dos temas mais abordados nos projetos de estruturação em data analytics, sendo um dos principais indicadores do nível de maturidade das organizações. Um dos problemas mais comuns de qualidade é relacionado à completude de dados. Em suas palavras, como é definido completude? Qual o impacto em uma análise exploratória de dados?**

Resposta: A completude de dados faz referência ao grau em que os dados estão completos. Isso mede o quanto as informações necessárias estão efetivamente preenchidas nas variáveis analisadas. O impacto dessa completude em uma EDA significa que os valores faltantes podem comprometer toda análise estatística, reduzir a confiabilidade e dificultar a aplicação de modelos estatísticos. Logo, a completude é essencial para a qualidade e precisão das análises.

7. **Qual a completude para cada uma das variáveis do seu banco de dados?**

Resposta:

```r
{r}
#questão 07, cálculo da completudo:
# Percentual de valores não nulos (completude)

completude <- sapply(df, function(x) {
  sum(!is.na(x)) / length(x) * 100
})

completude
```

```
          age       weight       height     exercise        sleep sugar_intake
 smoking      alcohol
          100          100          100          100          100          100
 100          100
      married   profession          bmi  health_risk
          100          100          100          100
```

Como minha base de dados original não apresentava valores faltantes, foram inseridos valores ausentes de forma artificial em algumas variáveis.

Correção para inserir dados faltantes:

```r
{r}
set.seed(123)

df_missing <- df

# Inserindo NA em 5% dos dados
df_missing$bmi[sample(1:nrow(df), 0.05 * nrow(df))] <- NA
df_missing$sleep[sample(1:nrow(df), 0.05 * nrow(df))] <- NA
```

```r
{r}
#questão 07 editada para dados faltantes:

completude <- sapply(df_missing, function(x) {
  sum(!is.na(x)) / length(x) * 100
})

completude
```

```
          age       weight       height     exercise        sleep sugar_intake
 smoking      alcohol
          100          100          100          100           95          100
 100          100
      married   profession          bmi  health_risk
          100          100           95          100
```

Os resultados indicam que algumas variáveis apresentam valores inferiores a 100% de completude, evidenciando a presença de dados faltantes. Os valores ausentes podem impactar a análise exploratória, reduzindo a quantidade de dados disponíveis e podendo introduzir viés nos resultados. Sendo assim é necessário aplicar técnicas de tratamento, como imputação, para garantir maior qualidade e confiabilidade na análise.

8. **Realize uma operação de imputação de dados usando o pacote MICE.**

Resposta:

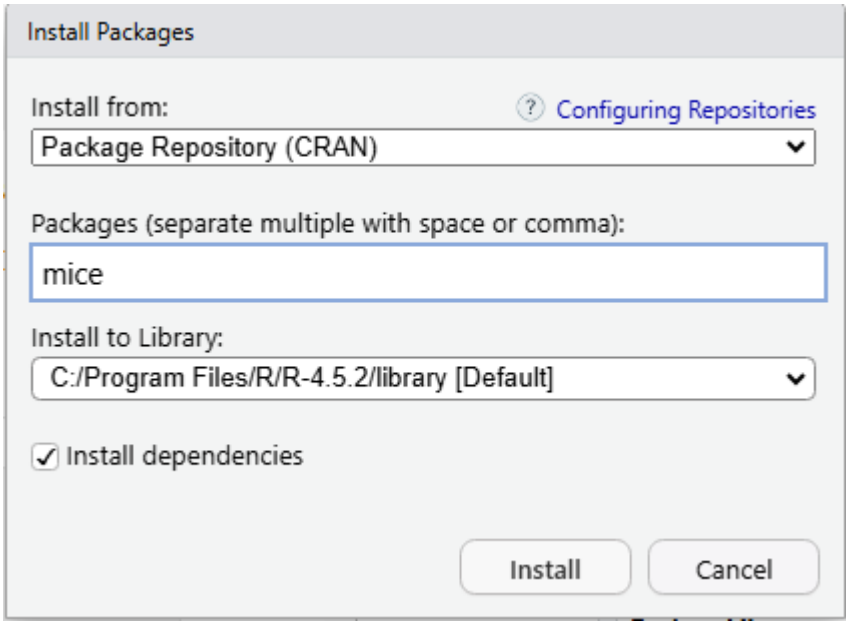


```r
{r}
#questão 08
library(mice)

df_mice <- df_missing |>
  select(age, bmi, sleep, weight)

imputacao <- mice(df_mice, m = 5, method = 'pmm', seed = 123)

df_imputado <- complete(imputacao)
```

```
Aviso: pacote ‘mice’ foi compilado no R versão 4.5.3
```

```
> imputacao <- mice(df_mice, m = 5, method = 'pmm', seed = 123)

 iter imp variable
  1   1  bmi  sleep
  1   2  bmi  sleep
  1   3  bmi  sleep
  1   4  bmi  sleep
  1   5  bmi  sleep
  2   1  bmi  sleep
  2   2  bmi  sleep
  2   3  bmi  sleep
  2   4  bmi  sleep
  2   5  bmi  sleep
  3   1  bmi  sleep
  3   2  bmi  sleep
  3   3  bmi  sleep
  3   4  bmi  sleep
  3   5  bmi  sleep
  4   1  bmi  sleep
  4   2  bmi  sleep
  4   3  bmi  sleep
  4   4  bmi  sleep
  4   5  bmi  sleep
  5   1  bmi  sleep
  5   2  bmi  sleep
  5   3  bmi  sleep
  5   4  bmi  sleep
  5   5  bmi  sleep
>
> df_imputado <- complete(imputacao)
>
```

A imputação foi realizada em uma base contendo valores ausentes que precisei inserir. O método utilizado foi o Predictive Mean Matching (pmm), que preserva a distribuição original dos dados e evita a geração de valores inconsistentes.

9. **Crie um dashboard Shiny onde seja possível selecionar (tire um print-screen da tela final do sistema):**

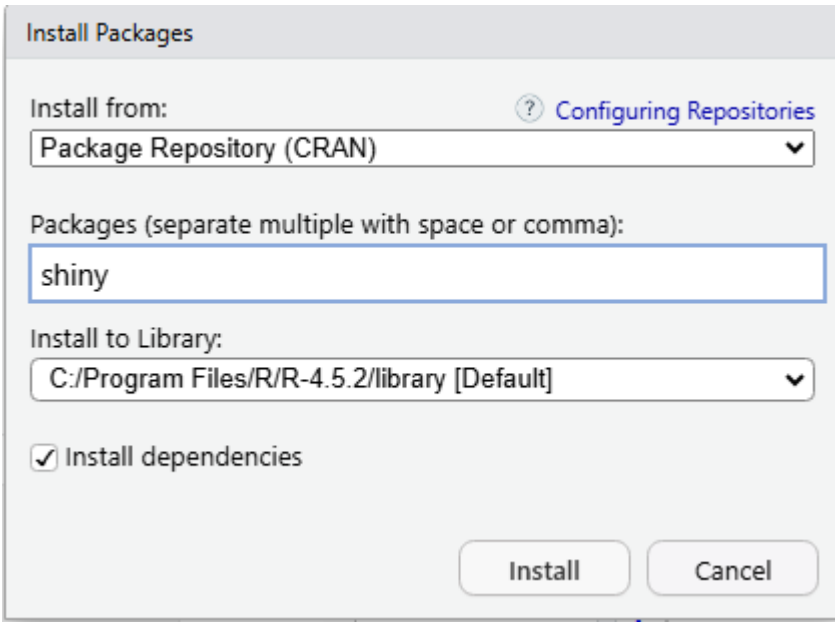

a. **uma variável da sua base de dados e um gráfico em linha seja mostrado na tela;**
b. **escolher a cor da linha do gráfico;**
c. **selecionar o limite inferior e superior do eixo X do gráfico;**
d. **selecionar o limite inferior e superior do eixo Y do gráfico.**

Respostas:

```r
library(shiny)
library(ggplot2)
library(dplyr)

df <- read.csv("Lifestyle_and_Health_Risk_Prediction_Synthetic_Dataset.csv")

df_num <- df |>
  select(age, bmi, sleep, weight)

ui <- fluidPage(

  selectInput("variavel", "Escolha a variável:",
              choices = names(df_num)),

  selectInput("cor", "Escolha a cor:",
              choices = c("blue", "red", "green")),

  sliderInput("x", "Limite do eixo X:",
              min = 1, max = nrow(df_num),
              value = c(1, 100)),

  sliderInput("y", "Limite do eixo Y:",
              min = 0, max = max(df_num, na.rm = TRUE),
              value = c(0, 100)),

  plotOutput("grafico")
)

server <- function(input, output) {

  output$grafico <- renderPlot({

    dados <- df_num |>
      mutate(index = row_number())

    ggplot(dados, aes(x = index, y = .data[[input$variavel]])) +
      geom_line(color = input$cor) +
      xlim(input$x[1], input$x[2]) +
      ylim(input$y[1], input$y[2])

  })
}

shinyApp(ui = ui, server = server)
```

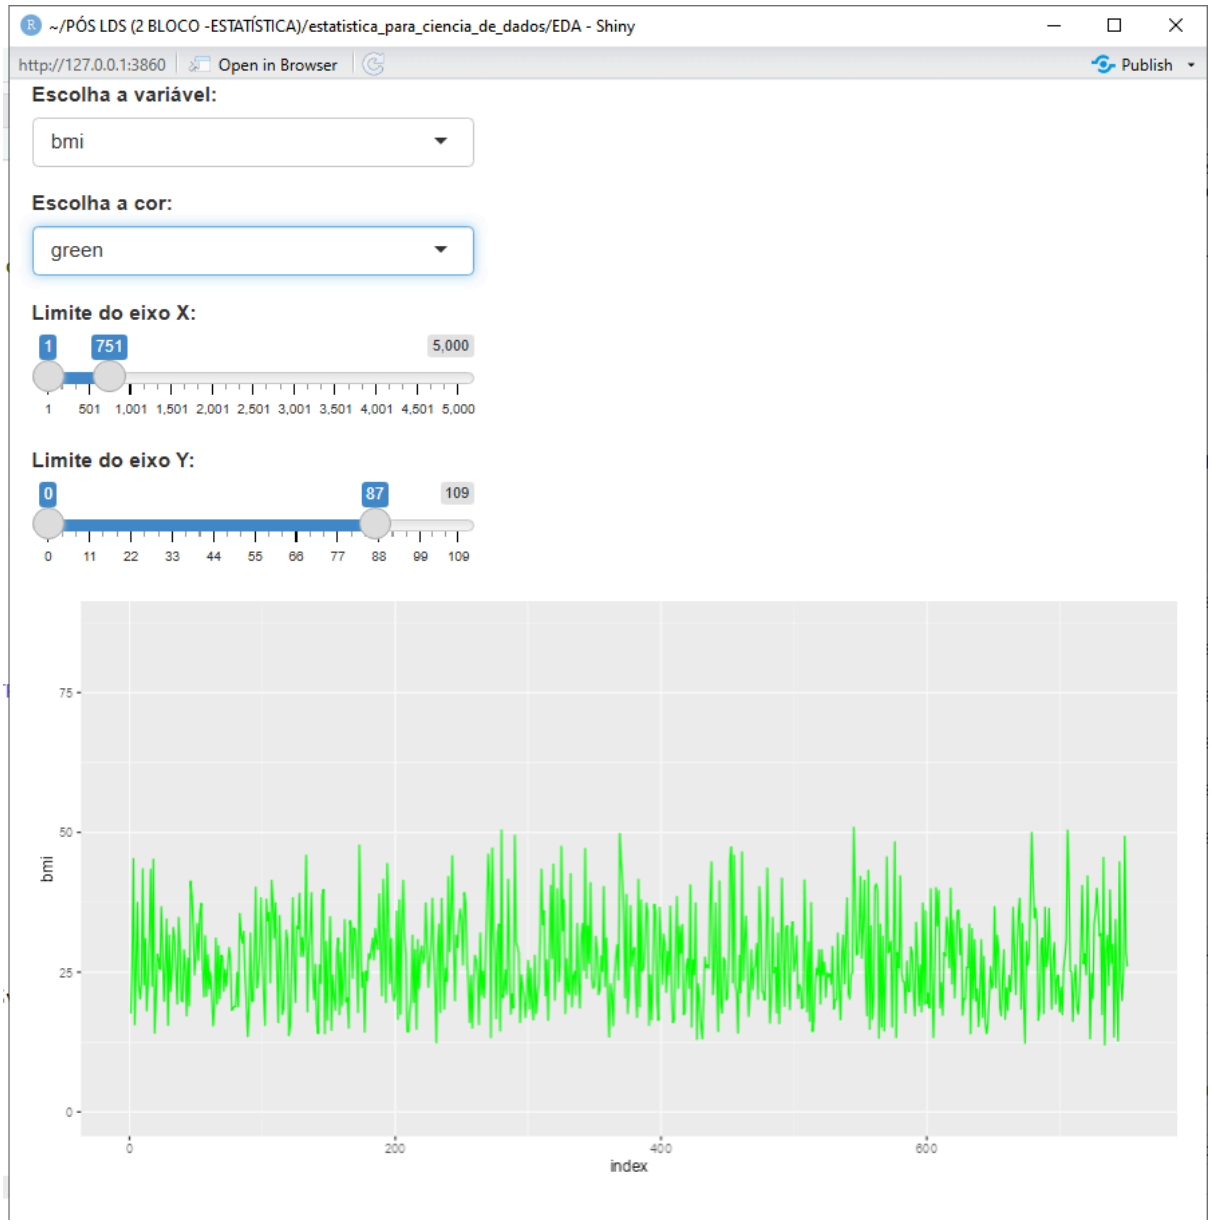
~/PÓS LDS (2 BLOCO -ESTATÍSTICA)/estatistica_para_ciencia_de_dados/EDA - Shiny
http://127.0.0.1:3860
Open in Browser
Publish
Escolha a variável:
bmi
Escolha a cor:
green
Limite do eixo X:
1
751
5,000
1 501 1,001 1,501 2,001 2,501 3,001 3,501 4,001 4,501 5,000
Limite do eixo Y:
0
87
109
0 11 22 33 44 55 66 77 88 99 109
75
50
25
0
bmi
0
200
400
600
index

10. **Disponibilize os códigos (RMarkdown e Shiny) em uma plataforma de compartilhamento de códigos (sugestão GitHub)**

Resposta: https://github.com/acarlaassis/projeto-eda-carla